

HA NOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

School of Information and Technology



SOICT

Project 2

Mã môn học : IT3930E

Huấn luyện mô hình học sâu ứng dụng cho phát hiện ảnh/video DeepFake

NGUYỄN TIẾN THÀNH

thanh.nt225459@sis.hust.edu.vn

GVHD : Dr. Trần Văn Đặng

HÀ NỘI, 6/2025

LỜI CẢM ƠN

Trước tiên, em xin gửi lời cảm ơn trân thành và sâu sắc nhất đến giảng viên hướng dẫn TS. Trần Văn Đặng, người đã cung cấp các góc nhìn cũng như đưa ra các định hướng, góp ý để em áp dụng trong suốt quá trình thực hiện đồ án môn học này. Sự hỗ trợ và chỉ dẫn của thầy đã giúp em hoàn thành đề tài cũng như giúp em có cơ hội học thêm về các kỹ năng phát triển web, cũng như ứng dụng các mô hình học sâu vào các hệ thống web để cung cấp giải pháp cho người dùng.

Dù em đã cố hết sức có thể để hoàn thiện đồ án môn học này, em hiểu rằng kỹ năng bản thân vẫn còn có hạn và còn rất nhiều thiếu sót trong quá trình phát triển một ứng dụng web hoàn thiện. Em rất mong nhận được sự góp ý từ thầy để tiếp tục nâng cao kiến thức và cải thiện kỹ năng của mình trong tương lai.

TÓM TẮT NỘI DUNG BÁO CÁO

Với sự phát triển của AI tạo sinh cũng như các kỹ thuật chỉnh sửa ảnh, những nội dung trên không gian mạng hoàn toàn có thể bị chỉnh sửa hoặc là giả. Vì thế nhu cầu tìm ra một phương pháp giúp phân biệt các loại nội dung này ngày càng tăng cao, khi mà các mô hình AI tạo sinh ngày càng tiến bộ, thì các phương pháp để phân biệt nội dung do chúng tạo ra cũng phải phát triển theo tương ứng.

Dự án này tập trung vào việc huấn luyện các mô hình học sâu ResNet và EfficientNet đã qua huấn luyện với các tập dữ liệu lớn cho tác vụ phát hiện nội dung Deep Fake và AI sinh ra, cụ thể là hình ảnh và video. Kết quả trên tác vụ phát hiện ảnh cho độ chính xác 98.45% trên tập kiểm thử CIFAKE, vượt qua các phương pháp mới nhất trên cùng tập dữ liệu. Với tác vụ phát hiện video, kết quả cho ra độ chính xác 91.27% trên tập kiểm thử.

Contributing student
Sign and write full name

Thành

Nguyễn Tiến Thành

MỤC LỤC

CHƯƠNG 1. GIỚI THIỆU BÀI TOÁN.....	5
1. Giới thiệu chung.....	
2. Phương pháp.....	6
CHƯƠNG 2. TẬP DỮ LIỆU.....	7
1. CIFAKE.....	7
2. DFD - Face Forensics.....	9
CHƯƠNG 3. PHÂN TÍCH MÔ HÌNH VÀ KẾT QUẢ.....	10
1. ResNet.....	11
2. EfficientNet.....	12
3. Kết quả.....	16
CHƯƠNG 4. ỨNG DỤNG MÔ HÌNH VÀO WEBSITE	19
1. Kiến trúc hệ thống.....	19
2. Luồng hoạt động của người dùng.....	20
3. Sơ đồ Usecase.....	21
KẾT LUẬN	22
1. Kết luận.....	22
2. Phát triển trong tương lai.....	22
TÀI LIỆU THAM KHẢO	23

CHƯƠNG 1: GIỚI THIỆU BÀI TOÁN

1. Giới thiệu chung

Trong kỷ nguyên số bùng nổ hiện nay, chúng ta đang chứng kiến sự gia tăng chóng mặt của các nội dung kỹ thuật số bị làm giả, bị chỉnh sửa sai lệch, hay thậm chí là do Trí tuệ nhân tạo tạo sinh (Generative AI) tạo ra với mục đích tuyên truyền thông tin sai lệch. Từ những đoạn video giả mạo khuôn mặt của người nổi tiếng trong các bộ phim người lớn, cho đến những bài phát biểu của chính trị gia bị cắt ghép, chỉnh sửa nhằm bôi nhọ hay công kích cá nhân – ranh giới giữa thật và giả đang ngày càng trở nên mờ nhạt. Đáng báo động hơn, với sự phát triển của các công cụ mã nguồn mở ngày càng dễ tiếp cận và sử dụng, bất cứ ai, dù không chuyên, cũng có thể dễ dàng tạo ra những nội dung AI này để trục lợi cho cá nhân.


Chính từ thực trạng đáng lo ngại này, việc tìm ra một phương pháp hiệu quả để phân biệt nội dung "thật" và nội dung do AI tạo ra trên không gian mạng đã trở thành một bài toán sống còn đối với các doanh nghiệp lớn trên thế giới. Điển hình như Pinterest, một nền tảng chia sẻ hình ảnh khổng lồ, đang phải đối mặt với làn sóng người dùng rời bỏ ứng dụng. Lý do là nội dung hiển thị trên trang đề xuất của họ tràn ngập hình ảnh do AI tạo ra, điều mà người dùng cho rằng đã làm giảm trải nghiệm sử dụng và gây ra cảm giác khó chịu. Đây không chỉ là vấn đề của riêng Pinterest, mà còn là thách thức chung mà toàn xã hội đang phải đối mặt trong cuộc chiến chống lại thông tin sai lệch và nội dung giả mạo.



Hình 1.1 Liệu người dùng có thể nhận ra 4 bức hình này đến từ AI ?


2. Phương pháp

Trong báo cáo này, em sẽ tập trung vào hai vấn đề cốt lõi trong việc phát hiện nội dung Deep Fake: xác định xem liệu một hình ảnh hoặc video có phải do AI tạo ra hay đã bị chỉnh sửa hay không. Với mỗi loại dữ liệu, em sẽ đề xuất một mô hình học sâu chuyên biệt. Lý do em không sử dụng các mô hình đa phương thức (multimodal models) là bởi những mô hình này thường có kích thước rất lớn, đòi hỏi nhiều tham số và cấu trúc mạng sâu, điều mà điều kiện phần cứng cá nhân hiện tại của em chưa thể đáp ứng được.



Hình 1.2 Cấu trúc ResNet50

Cụ thể hơn, với tác vụ phát hiện ảnh, em sẽ sử dụng mô hình ResNet50. Mô hình này là một bước đột phá trong lĩnh vực học sâu, khi đã đề xuất một phương pháp mới để xử lý vấn đề mất thông tin trong mạng tích chập sâu (Deep Convolutional Neural Network). Với tác vụ phát hiện cho video, em sẽ sử dụng EfficientNet B0, một mô hình nhẹ (lightweight) tuy nhiên vẫn giữ hiệu suất cao trong các tác vụ thị giác máy tính. Cả hai mô hình đều đã được huấn luyện trước với bộ dữ liệu ImageNet. Bằng cách tận dụng tri thức cả hai mô hình đã được học, em sẽ thực hiện tinh chỉnh cả hai mô hình để phù hợp hơn cho các tác vụ phát hiện Deep Fake.



Hình 1.3 Cấu trúc EfficientNet-B0

CHƯƠNG 2. TẬP DỮ LIỆU


1. CIFAKE

Nhằm phục vụ cho bài toán phân loại ảnh do trí tuệ nhân tạo (AI) tạo ra, Jordan J.Bird và cộng sự đã xây dựng bộ dữ liệu tổng hợp CIFAKE [1]. Bộ dữ liệu này được tạo ra bằng mô hình khuếch tán (Latent Diffusion Model - LDM) dựa trên tập dữ liệu CIFAR-10. Ban đầu, CIFAR-10 bao gồm 10 lớp đối tượng, mỗi lớp có 6000 mẫu ảnh, được chia thành 5000 mẫu cho huấn luyện và 1000 mẫu cho đánh giá. Trong quá trình tạo CIFAKE, 60,000 mẫu ảnh "thật" từ CIFAR-10 (ứng với 10 lớp) được gán nhãn "REAL" và phân chia theo tỷ lệ 50,000 cho huấn luyện và 10,000 cho đánh giá. Tiếp theo, nhóm nghiên cứu đã sử dụng các câu lệnh gợi ý (prompts) để LDM tạo ra 60,000 mẫu ảnh "giả" tương ứng với 10 lớp, mỗi lớp 6000 mẫu.



Hình 2.1 Bộ dữ liệu CIFAR-10

Kết quả là, tập dữ liệu CIFAKE được hình thành với tổng cộng 100,000 mẫu cho huấn luyện và 20,000 mẫu cho đánh giá, duy trì sự cân bằng giữa các lớp với tỷ lệ 1:1



Hình 2.2 Bộ dữ liệu CIFAKE

Class Label	Prompt Modifiers
<i>Airplane</i>	<i>:- aircraft, airplane, fighter, flying, jet, plane</i>
<i>Automobile</i>	<i>:- family, new, sports, vintage</i>
<i>Bird</i>	<i>:- flying, in a tree, indoors, on water, outdoors, walking</i>
<i>Cat</i>	<i>:- indoors, outdoors, walking, running, eating, jumping, sleeping, sitting</i>
<i>Deer</i>	<i>:- herd, in a field, in the forest, outdoors, running, wildlife photography</i>
<i>Dog</i>	<i>:- indoors, outdoors, walking, running, eating, jumping, sleeping, sitting</i>
<i>Frog</i>	<i>:- European, in the forest, on a tree, on the ground, swimming, tropical, wildlife photography</i>
<i>Horse</i>	<i>:- herd, in a field, in the forest, outdoors, running, wildlife photography</i>
<i>Ship</i>	<i>:- at sea, boat, cargo, cruise, on the water, river, sailboat, tug</i>
<i>Truck</i>	<i>:- 18-wheeler, car transport, fire, garbage, heavy goods, lorry, mining, tanker, tow</i>

Hình 2.3 Prompt modifiers được sử dụng để sinh ra bộ dữ liệu CIFAKE

Trong bối cảnh các mô hình khuếch tán (Diffusion Models) ngày càng chứng minh ưu thế vượt trội so với mạng sinh đối nghịch (GANs) trong nhiều tác vụ sinh ảnh, bộ dữ liệu CIFAKE mang đến một nguồn tài nguyên quý giá cho cộng đồng nghiên cứu. Nó tạo điều kiện thuận lợi cho việc khám phá các đặc trưng tiềm ẩn trong quá trình LDM tạo ra nội dung. Một ưu điểm nổi bật khác của bộ dữ liệu này là sự phân bố đồng đều về số

lượng mẫu giữa các lớp, cùng với quy mô đủ lớn để các mô hình học sâu có thể phát huy tối đa khả năng học từ dữ liệu.

2. DFD - Face Forensics

DeeperForensics-1.0 (DFD) là một tập dữ liệu mới được thiết kế đặc biệt cho bài toán phát hiện giả mạo khuôn mặt (DeepFake) trong môi trường thực tế, nổi bật với ba thuộc tính: chất lượng tốt, quy mô lớn và tính đa dạng cao. Toàn bộ tập dữ liệu bao gồm 48,475 video gốc và 11,000 video đã bị chỉnh sửa, lớn hơn đáng kể so với các tập dữ liệu hiện có [3].

Các video gốc được thu thập cẩn thận từ 100 diễn viên được trả tiền và có sự đồng thuận đến từ 26 quốc gia khác nhau. Các video bị chỉnh sửa được tạo ra bằng phương pháp hoán đổi khuôn mặt "nhiều-đối-nhiều" (many-to-many) từ đầu đến cuối (end-to-end) mới được đề xuất, có tên là DF-VAE. Hơn nữa, để đảm bảo quy mô lớn hơn và tính đa dạng cao hơn, tập dữ liệu này còn áp dụng 7 loại nhiễu thực tế ở 5 mức cường độ khác nhau. Những đặc điểm này biến DFD thành một nguồn tài nguyên quý giá cho việc nghiên cứu và phát triển các hệ thống phát hiện giả mạo khuôn mặt mạnh mẽ và đáng tin cậy.


Tuy nhiên do kích cỡ của bộ dữ liệu gốc quá lớn (284 GBs), nên em sẽ chỉ sử dụng một phần nhỏ của bộ dữ liệu. Cụ thể là 3068 video đã qua chỉnh sửa và 364 video gốc, với tổng kích cỡ là 24 GBs.

CHƯƠNG 3. PHÂN TÍCH MÔ HÌNH VÀ KẾT QUẢ

1. ResNet


Trước khi mô hình ResNet được đề xuất bởi Kaiming He và các đồng nghiệp (2015), mạng nơ-ron truyền thống (cả mô hình perceptron đa lớp và mạng tích chập) đều phải đối mặt chung với một vấn đề, đó là các mô hình này không đem lại hiệu quả cao hơn khi sử dụng nhiều lớp hơn. Trên lý thuyết, mạng nơ-ron có thể coi như một hàm số xấp xỉ ánh xạ từ đầu vào tới đầu ra. Việc thêm lớp cho mô hình khiến chúng có khả năng bắt được những cấu trúc phức tạp hơn, tuy vậy kết quả thực nghiệm lại chỉ ra

điều trái ngược, khi mà mô hình sâu hơn lại đem lại kết quả tệ hơn những mô hình kích thước trung bình.



Hình 3.1 Lỗi huấn luyện và lỗi kiểm thử trên tập dữ liệu CIFAR-10, với hai mô hình có kích thước 20 lớp và 56 lớp. Mô hình có nhiều lớp hơn có lỗi huấn luyện và lỗi kiểm thử cao hơn. Điều này cũng xảy ra khi huấn luyện mô hình với các tập dữ liệu khác như ImageNet.

Hiện tượng này có thể được giải thích theo lý thuyết hàm số: khi tăng số lớp cho mô hình thì mô hình sẽ có khả năng học được nhiều họ hàm số phức tạp hơn, do số lượng tham số cũng khi các phép biến đổi nhiều hơn. Nói cách khác, khi kích thước mô hình, không gian hàm số mà mô hình biểu đạt sẽ rộng hơn. Tuy nhiên khi không gian hàm số lớn hơn có thể xảy ra một vấn đề, đó là miền không gian mới có thể bị dịch ra khỏi vị trí ban đầu (hình 3.2 sẽ minh họa điều này). Việc tăng không gian hàm số có thể tăng tỷ lệ tìm được hàm số tối ưu, nhưng do miền tìm kiếm bị thay đổi, có thể ta sẽ ở quá xa nơi mà kết quả tìm kiếm tồn tại. Điều này cũng lý giải một phần vì sao mô hình sâu hơn lại đem lại kết quả tệ hơn những mô hình nhỏ hơn tương ứng.




Hình 3.2 Khi tăng kích thước mô hình, không gian hàm số sẽ rộng hơn, tuy nhiên nó có thể bị dịch ra khỏi vị trí muốn tìm kiếm ban đầu, khiến cho việc tìm kiếm kết quả tối ưu trở nên khó khăn.

Một giải pháp được đưa ra, là một trong những nền tảng của ResNet, đó chính là việc lồng ghép (nested) các hàm số lại với nhau (hình minh hoạ 3.2 bên phải). Phương pháp này giải quyết các vấn đề như sau: không gian hàm số mở rộng ra có bao hàm cả không gian hàm số cũ, tức là khi đã tìm được một hàm số tối ưu ở không gian cũ, thì khi chuyển sang không gian mới vẫn sẽ bảo đảm rằng kết quả tìm được có cận dưới là hàm số đó, từ đó tránh được vấn đề xuống cấp (degradation) khi triển khai mô hình sâu hơn từ các mô hình đã có hiệu năng tốt.

Từ những lý thuyết trên, nhóm tác giả đã đề xuất một phương pháp để giải quyết vấn đề nêu trên trong mạng tích chập, đó là khái niệm “học sâu thặng dư” (deep residual learning). Học sâu thặng dư cải tiến các lớp trong mạng nơ-ron để học hàm thặng dư với tham chiếu đến các lớp đầu vào, thay vì học hàm không tham chiếu trực tiếp. Với mạng tích chập truyền thống, các lớp tích chập sẽ có vai trò ánh xạ một đầu vào x đến đầu ra $H(x)$. Tuy nhiên trong mạng thặng dư, các lớp tích chập sẽ được chồng lên nhau để học một ánh xạ thặng dư $F(x) := H(x) - x$. Vì thế ánh xạ đầu ra sẽ là $F(x) + x$. Cách làm này dựa trên giả thuyết rằng, việc tối ưu ánh xạ thặng dư sẽ dễ hơn so với ánh xạ trực tiếp trong phương pháp truyền thống. Nếu như ánh xạ đồng nhất (identity mapping)¹ là tối ưu, thì việc đẩy tham số thặng dư tiến về 0 sẽ thuận lợi hơn so với việc học lại ánh xạ đó từ đầu bằng cách sử dụng nhiều lớp tích chập phi tuyến. Các lớp này có cấu trúc như sau:

Hình 3.3 Mô hình của Residual

Block được đơn giản hoá, có thể thấy rằng nếu bỏ đi skip-connection thì khối này chính là khối convolution/fully connected layer.



Bằng cấu trúc này, mô hình Residual Network đảm bảo rằng trong cùng một họ mô hình ResNet, khi được huấn luyện trên cùng một tập dữ liệu thì mô hình lớn hơn sẽ cho kết quả tốt hơn những mô hình trước. Ngoài ra kỹ thuật skip-connection còn được ứng dụng rất nhiều trong các tác vụ như mô hình ngôn ngữ lớn, cấu trúc mã hoá-giải mã, Từ tất cả những điều kể trên, mô hình ResNet là một lựa chọn tốt cho các tác vụ liên quan đến thị giác máy tính, đặc biệt là tác vụ phân loại ảnh, trọng tâm của dự án này.

¹ Ánh xạ từ x đến $F(x)$ là đồng nhất khi $F(x) = x$.

2. EfficientNet

Từ sau sự ra đời của các mô hình học sâu tích chập, đã có rất nhiều cách để tăng hiệu năng của mô hình, trong đó phổ biến nhất là mở rộng quy mô của mô hình (scale-up). Đã có rất nhiều mô hình tận dụng cách làm này, có thể kể đến như ResNet (He và các đồng nghiệp, 2015), GPipe (Huang và các đồng nghiệp, 2018) đã tăng hiệu năng của mô hình chỉ dựa trên phương pháp tăng số lượng lớp từ mô hình nền tảng (baseline model). Việc mở rộng mô hình có nhiều cách, trong đó phổ biến nhất gồm ba phương pháp: mở rộng theo chiều sâu (depth scaling), mở rộng theo chiều rộng (width scaling) và mở rộng theo độ phân giải (resolution scaling), tiếp theo ta sẽ đi tìm hiểu qua về từng phương pháp, và cách Mingxing Tan & Le Viet Quoc đã sử dụng để thiết kế ra họ mô hình EfficientNet [6], đem lại cách mạng cho việc xây dựng các mô hình học sâu tối ưu về cả hiệu năng lẫn kích thước.




Diagram 3.4 Mở rộng theo chiều rộng

Đầu tiên là việc mở rộng theo chiều rộng, cách này được dùng chủ yếu cho các mô hình nhỏ, mở rộng mô hình cho phép mô hình bắt được nhiều đặc trưng chi tiết hơn. Tuy vậy chỉ chú trọng vào chiều rộng, mô hình sẽ không

có khả năng học được đặc trưng bậc cao (higher-level features) do các đặc trưng này nằm phần lớn ở các lớp sâu hơn.





Diagram 3.5 Mở rộng theo chiều sâu

Phương pháp mở rộng theo chiều sâu là phương pháp được sử dụng phổ biến nhất, bằng việc thêm các lớp phi tuyến, mô hình có thể trích xuất được nhiều đặc trưng bậc cao hơn, từ đó đem lại khả năng tổng quát hoá tốt hơn. Tuy nhiên mô hình quá sâu thường dẫn đến nhiều vấn đề như đã đề cập trong mục 3.1 khi nói về cấu trúc ResNet.



(d) resolution scaling

Diagram 3.6 Mở rộng theo độ phân giải

Nội dung có độ phân giải cao hơn cho phép mô hình bắt được nhiều họa tiết hơn, nhưng tăng độ phân giải cũng đồng nghĩa với tăng độ phức tạp tính toán. Những mô hình truyền thống thường sử dụng độ phân giải 224x224, các mô hình mới gần đây có xu hướng tăng độ phân giải để giữ được nhiều thông tin hơn của dữ liệu gốc.

Tuy việc mở rộng mô hình đem lại kết quả tốt, đã được kiểm chứng ở các mô hình như ResNet, GPIPE, ... Nhưng đổi lại, chi phí tính toán cũng tăng đột biến, lý do là vì mở rộng mô hình đồng nghĩa với tăng số lượng tham số, từ đó dẫn đến tăng độ phức tạp tính toán trong cả quá trình huấn luyện lẫn kiểm thử.

Nhóm tác giả của EfficientNet đã áp dụng một phương pháp có tên là compound scaling, rằng thay vì mở rộng mô hình theo một tiêu chí riêng lẻ (độ sâu, chiều rộng, ...), họ sẽ mở rộng mô hình theo nhiều tiêu chí cùng lúc, đồng thời họ cũng nhận thấy rằng việc cân bằng giữa các yếu tố theo một tỷ lệ đem lại kết quả tốt hơn việc tăng một yếu tố riêng lẻ.




Diagram 3.7 Compound Scaling

Hệ số compound scaling điều chỉnh ba chiều tham số (chiều sâu, chiều rộng và độ phân giải) theo một tỷ lệ sử dụng hệ số compound ϕ xác định trước.

$$\begin{aligned}
&\text{depth: } d = \alpha^\phi \\
&\text{width: } w = \beta^\phi \\
&\text{resolution: } r = \gamma^\phi \\
&\text{s.t. } \alpha \cdot \beta^2 \cdot \gamma^2 \approx 2 \\
&\alpha \geq 1, \beta \geq 1, \gamma \geq 1
\end{aligned}$$

Diagram 3.8 Biểu thức toán cho hệ số compound

Từ biểu thức này, chúng ta có thể xác định nên điều chỉnh mô hình như nào để đem lại hiệu quả tốt nhất. Việc sử dụng compound scaling sẽ giúp tối ưu tài nguyên sử dụng, tránh các vấn đề xảy ra khi chỉ áp dụng mở rộng theo một tiêu chí (vanishing gradient với mở rộng theo chiều sâu hoặc bão hoà-saturation khi mở rộng theo chiều rộng). Ngoài ra thực nghiệm chứng minh rằng cân bằng các yếu tố kể trên giúp mô hình đạt được kết quả bằng hoặc tốt hơn với chi phí tính toán thấp hơn đáng kể so với các mô hình trước đó. Điều này giúp cho họ mô hình EfficientNet phù hợp cho các tác vụ mà thiết bị thực hiện tính toán không quá mạnh.

Trong đề tài này, em sẽ sử dụng mô hình EfficientNet-B0 cho tác vụ dự đoán xem liệu video có phải nội dung đã qua chỉnh sửa hoặc deepfake hay không. Do đặc trưng của dữ liệu video khác với hình ảnh, nên cách xử lý dữ liệu để có thể tận dụng tối đa tri thức của mô hình đã qua huấn luyện cũng cần được lưu ý. Em sẽ sử dụng phương pháp tách khung hình ra khỏi video gốc, video sẽ được chuyển thành một chuỗi các hình ảnh liên tục, nối tiếp nhau. Việc áp dụng các phương pháp biến đổi như chuẩn hoá, thay đổi độ phân giải sẽ được thực hiện với từng ảnh. Thay vì phải xử lý toàn bộ video, mô hình sẽ xử lý một chuỗi hình ảnh, tận dụng tối đa khả năng của EfficientNet-B0 do mô hình này được tiền huấn luyện trên tập dữ liệu hình ảnh và cấu trúc của nó không bao gồm các khối có khả năng bắt được dữ liệu theo thời gian như Convolution3D.

3. Kết quả

Cả hai mô hình trong đề tài này đều được huấn luyện trên GPU NVIDIA RTX 3070 - 8GB VRAM, 16GB RAM và CPU Intel Core i7-12700K.

- **Dự đoán hình ảnh:** Với mô hình đã qua huấn luyện ResNet50, em đã thực hiện huấn luyện tinh chỉnh với 100 epochs ~ 13.5 tiếng, sử dụng hàm

lỗi Cross Entropy, với bộ tối ưu Adam và áp dụng phương pháp thay đổi learning rate khi lỗi huấn luyện bị chững lại. Tất cả số liệu đánh giá dưới đây đều được đo trên tập kiểm thử, tập mà mô hình chưa được thấy trong quá trình huấn luyện.

	Mô hình	Precision	Recall	F1-Score	Accuracy	ROC-AUC
[4]	ResNet-50	0.95	0.95	0.95	95.00	99
	VGGNet	0.96	0.96	0.96	96.00	99
	DenseNet	0.98	0.98	0.98	98.00	99
[5]	Binary NeuralNet	N/A	N/A	N/A	97.35	99.62
Mine	ResNet-50	0.98	0.98	0.98	98.45	99.86

Diagram 3.9 Bảng so sánh kết quả huấn luyện




Diagram 3.10 Ma trận nhầm lẫn




Diagram 3.11 đường cong ROC với $AUC = 0.9986$

- **Dự đoán video:** Với mô hình đã qua huấn luyện EfficientNet-B0, em đã thực hiện phương pháp huấn luyện progressive fine tuning do dữ liệu đầu vào và kiến trúc mô hình đến từ việc huấn luyện trước là khác nhau. Quy trình của phương pháp này sẽ bao gồm hai bước, bước đầu em sẽ đóng băng toàn bộ tham số của mô hình, trừ lớp phân loại phi tuyến được thêm mới vào mô hình để phục vụ cho việc phân loại Deep Fake. Bước hai sẽ mở khóa toàn bộ tham số, cho phép huấn luyện toàn bộ mô hình với dữ liệu, tuy nhiên sẽ để learning rate rất thấp. Lý do là vì mô hình tiền huấn luyện đã có tri thức nhất định với việc biến đổi ảnh đầu vào thành dữ liệu vector để bộ phân loại xử lý, nên ở giai đoạn đầu sẽ chỉ cần tập trung vào việc huấn luyện bộ phân loại mới được thêm vào. Ở giai đoạn hai thì do ta không muốn các tham số đã qua huấn luyện của mô hình bị thay đổi quá đột ngột, mất đi tri thức có sẵn nên sẽ sử dụng learning rate rất nhỏ để hạn chế điều này. Phương pháp này rất phổ biến trong transfer-learning, khi chúng ta muốn tận dụng sức mạnh của mô hình tiền huấn luyện để thích ứng với tác vụ mới.

Kết quả thu được sau 3 epochs giai đoạn I, 5 epochs giai đoạn II ~ 11 tiếng cho ra kết quả **91.27% Accuracy** trên tập kiểm thử. Do bộ dữ liệu em lựa chọn ngẫu nhiên từ bộ dữ liệu gốc nên không có các mô hình tương tự để so sánh.

CHƯƠNG 4. ỨNG DỤNG MÔ HÌNH VÀO WEBSITE

1. Kiến trúc hệ thống

Để đưa mô hình phát hiện DeepFake vào ứng dụng thực tế, một trang web chia sẻ hình ảnh tương tự Pinterest đã được phát triển. Website cho phép người dùng tải lên hình ảnh, chia sẻ và tương tác với các hình ảnh, đồng thời tích hợp mô hình đã huấn luyện để tự động phân loại và dán nhãn các nội dung do AI tạo ra.

Hệ thống được xây dựng sử dụng các framework dành cho web nổi tiếng, đảm bảo tính linh hoạt và khả năng mở rộng. Cụ thể hơn, **Backend** sẽ sử dụng **NodeJS** để xử lý các request từ phía client, bao gồm các yêu cầu về đăng nhập, đăng ký, ... cũng như tải lên hình ảnh và gửi trả thông tin cá nhân. Đặc biệt khi người dùng tải ảnh lên, backend sẽ gọi đến mô hình học sâu đã được huấn luyện kể trên để xử lý dữ liệu, sau đó trả về kết quả tương ứng. **Frontend** sẽ được xây dựng bằng **ReactJS**, được thiết kế tối giản để người dùng không quá tải với lượng thông tin lớn và thân thiện với người mới sử dụng. Về cơ sở dữ liệu, em sẽ sử dụng **MongoDB** để lưu trữ các thông tin như thông tin tài khoản người dùng (tên đăng nhập, mật khẩu đã mã hoá), lịch sử phát hiện (ảnh nào đã được kiểm tra, kết quả, feedback, ..) và cả metadata của ảnh (tiêu đề, tags, lượt thích). Cùng với đó em còn sử dụng thêm **Cloudinary**, một dịch vụ lưu trữ đám mây cho media như ảnh hoặc video, nhưng tạm thời trong website này chỉ dùng để lưu trữ tệp hình ảnh.

2. Luồng hoạt động của người dùng

Quy trình tương tác của người dùng với website có thể gói gọn qua các tính năng cơ bản sau:

- **Đăng ký/Đăng nhập:** người dùng tạo tài khoản hoặc đăng nhập vào hệ thống.
- **Tải ảnh lên:** người dùng chọn một hoặc nhiều tệp ảnh từ thiết bị của mình để tải lên. Tại bước này, người dùng có thể thêm các thông tin mô tả cho ảnh như **tiêu đề** và các **thẻ (tags)** (ví dụ: "scenery", "portrait", "art", "selfie",).
- **Xử lý ảnh với mô hình học sâu:** sau khi ảnh được tải lên web, frontend sẽ gửi yêu cầu đến backend để xử lý ảnh này, backend sẽ gửi ảnh qua mô hình ResNet-50 đã được huấn luyện để phân tích hình ảnh và trả về kết quả dự đoán cùng với phần trăm tin cậy. Nếu mô hình cho rằng ảnh được gửi là do AI tạo ra, hệ thống sẽ gán nhãn "AI-Generated" cho ảnh. Nếu không thì ảnh sẽ được hiển thị bình thường kèm với nhãn của người dùng.
- **Hiển thị và tương tác:** xảy ra phần lớn ở phía client, ảnh sau xử lý sẽ được hiển thị trên trang chủ và mọi người dùng đều có thể thấy. Họ có thể xem, thấy được các tags và thực hiện các tương tác như thích ảnh, tìm kiếm theo tags, sử dụng bộ lọc AI, bookmark, Sau đó người dùng có thể xem lại nội dung mình đã bookmark trên profile cá nhân.

Đối với Admin, họ có thể quản lý người dùng, xem lịch sử dự đoán của hệ thống cùng với feedback.

3. Sơ đồ Usecase




Diagram 4.1 Sơ đồ usecase của người dùng cơ bản

KẾT LUẬN

1. Kết luận

Tổng kết, báo cáo này đã phân tích về các đặc trưng quan trọng của họ mô hình ResNet và EfficientNet, hai trong số nhiều họ mô hình nổi tiếng trong lĩnh vực học sâu, đồng thời áp dụng mô hình đã qua huấn luyện vào tác vụ phát hiện nội dung Deep Fake, với kết quả khả quan trong tác vụ phát hiện ảnh Deep Fake.

2. Phát triển trong tương lai

Trong tương lai, em sẽ phát triển mô hình đa phương thức, nhận đầu vào hình ảnh, video, văn bản hoặc âm thanh để phục vụ cho nhiều mục đích hơn do hiện tại nội dung Deep Fake hay AI-Generated đang tồn tại dưới rất nhiều hình thức. Với nội dung phát hiện video, em sẽ thay đổi phương pháp frame-based sang phương pháp temporal-based bằng cách sử dụng mô hình CNN có các lớp CONV3D để trích xuất đặc trưng theo thời gian, hoặc sử dụng các mô hình xử lý dữ liệu tuần tự như RNN, LSTM hay cấu trúc Vision Transformer cho tác vụ này để cải thiện hiệu năng.

Mã nguồn cho quá trình huấn luyện có thể tìm thấy tại link sau: [Mã nguồn huấn luyện](#)

Mã nguồn cho ứng dụng web có thể tìm thấy tại đây (do web chỉ triển khai trên localhost nên phải có file .env mới có thể chạy được): [Mã nguồn web](#)

Slide nội dung bao gồm demo web có thể xem tại đây: [Slide](#)

TÀI LIỆU THAM KHẢO

- [1] Bird, Jordan J., and Ahmad Lofti. “CIFAKE: Image Classification and Explainable Identification of AI-Generated Synthetic Images.” *IEEE Access*, 24 Mar 2023, pp. 15642-15650.
- [2] He, Kaiming, et al. “Deep Residual Learning for Image Recognition.” *arXiv:1512.03385*, 10 Dec 2015.
- [3] Jiang, Liming, and Zhengkui Guo. “DeeperForensics Challenge 2020 on Real-World Face Forgery Detection: Methods and Results.” *arXiv:2102.09471 [cs.CV]*, 18 Feb 2021.
- [4] Wang, Yuyang, et al. “Harnessing Machine Learning for Discerning AI-Generated Synthetic Images.” *arXiv:2401.07358*, 24 May 2024.
- [5] Romeo, Lanzino, et al. “Faster Than Lies: Real-time Deepfake Detection using Binary Neural Networks.” *arXiv:2406.04932*, 7 June 2024.
- [6] Tan, Mingxing, and Quoc V. Le. “EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks.” *arXiv:1905.11946*, 11 Sep 2020.