



**ĐẠI HỌC
BÁCH KHOA HÀ NỘI**
HANOI UNIVERSITY
OF SCIENCE AND TECHNOLOGY

Huấn luyện mô hình học sâu ứng dụng cho phát hiện ảnh/video DeepFake

Môn Học: Project 2

Mã Môn Học: IT3930E

Nguyễn Tiến Thành – 20225459

GVHD: TS. Trần Văn Đặng

ONE LOVE. ONE FUTURE.

Giới thiệu đề tài

- Trong thời đại các công cụ chỉnh sửa ảnh và công nghệ AI tạo sinh phát triển, nội dung bị chỉnh sửa hoặc nội dung AI tạo ra bắt đầu xuất hiện nhiều trên các mạng xã hội.
- Tuy những nội dung này thể hiện sự tiến bộ về mặt công nghệ, chúng có thể bị sử dụng cho các mục đích xấu, hoặc khiến người dùng khác cảm thấy phản cảm, khó chịu.



Giới thiệu đề tài

- Do sự tiến bộ công nghệ, những nội dung bị chỉnh sửa/AI tạo ra ngày càng khó phân biệt so với nội dung gốc, từ đó nảy sinh một nhu cầu cấp thiết đối với việc phân biệt nội dung do con người tạo ra và do AI tạo ra hoặc chỉnh sửa.




Phương án đề xuất

Trong đề án môn học này, em sẽ sử dụng các mô hình học sâu cho hai tác vụ là phát hiện ảnh và phát hiện video.


- **Với ảnh:** Sử dụng mô hình ResNet50, một mô hình đột phá trong lĩnh vực thị giác máy tính khi đã giải quyết vấn đề degradation của các mô hình tích chập sâu.
- **Với video:** Sử dụng mô hình EfficientNet-B0, một mô hình tập trung vào tốc độ xử lý.

Cả hai mô hình trên đều được tiền huấn luyện trên tập dữ liệu ImageNet1K, trên nền tảng đó em sẽ thực hiện finetune các mô hình này để giải quyết bài toán đặt ra.

Phương án đề xuất



Cấu trúc ResNet50




Cấu trúc EfficientNet-B0

Tập dữ liệu

Trong đề án này, em sẽ sử dụng hai tập dữ liệu là **CIFAKE** cho tác vụ phát hiện ảnh và **DFD - Face Forensics** cho tác vụ phát hiện video.

1.CIFAKE

Là tập dữ liệu synthetic được tạo ra từ tập CIFAR-10 bằng cách sử dụng mô hình Diffusion. Bao gồm 100,000 mẫu huấn luyện, trong đó có 50,000 mẫu được gán nhãn REAL và 50,000 mẫu được gán nhãn FAKE. Ngoài ra còn có thêm 20,000 mẫu được dùng để đánh giá kết quả cuối của mô hình.




Một vài mẫu từ tập dữ liệu CIFAKE


2. DFD - Face Forensics

Tập dữ liệu này bao gồm các video do các diễn viên được trả phí quay lại, rồi sau đó áp dụng các kỹ thuật chỉnh sửa DF-VAE, thay đổi khuôn mặt many-to-many từ đầu tới cuối, ngoài ra các video còn được thêm các nhiễu để video giống thực tế nhất có thể.

Tuy nhiên do tài nguyên phần cứng có hạn, chỉ một phần nhỏ tập dữ liệu được sử dụng để huấn luyện mô hình trong bài toán này.



Manipulated video




Original video

Tổng quan mô hình

1. ResNet50

Trước khi họ mô hình ResNet được đề xuất, các mô hình mạng tích chập đều gặp phải một vấn đề chung đó là degradation, đó là khi hiệu quả mô hình giảm khi kích thước và độ sâu tăng lên.

Nhóm tác giả đã đưa ra lý thuyết về Residual Learning, từ đó giúp họ mô hình ResNet giải quyết được vấn đề giảm hiệu năng khi tăng độ sâu mô hình.




Hiệu suất mô hình tích chập giảm khi tăng số lớp.

Nguồn: Deep Residual Learning for image recognition, Kaiming He et al.

Tổng quan mô hình

1. ResNet50

Với mạng tích chập truyền thống, các lớp tích chập sẽ có vai trò ánh xạ một đầu vào x đến đầu ra $H(x)$. Tuy nhiên trong mạng thặng dư, các lớp tích chập sẽ được chồng lên nhau để học một ánh xạ thặng dư $F(x) := H(x) - x$. Vì thế ánh xạ đầu ra sẽ là $F(x) + x$. Phương pháp này còn được gọi là skip-connection.



So sánh giữa khối Convolutional và khối Residual

Tổng quan mô hình

1. ResNet50


Skip-connection giúp mô hình học sâu giải quyết hai vấn đề chính đóng góp quan trọng dẫn đến degradation:

- **Vanishing gradients:** mô hình càng sâu thì khi gradients trong quá trình backpropagation có thể trở nên rất nhỏ do chain-rule. Do đó các lớp đầu của mô hình sẽ khó cập nhật tham số.
- **Information loss:** trong các mạng tích chập sâu, các lớp pooling tuy làm giảm kích thước dữ liệu, nhưng điều đó đồng nghĩa với việc làm mất phần lớn thông tin của input đầu vào. Bằng cách sử dụng skip-connection input gốc sẽ được thêm vào các lớp sâu hơn, từ đó giữ được các đặc trưng bậc thấp và bậc cao, có thể thấy rõ ràng hiệu quả trong các mô hình như U-Net, Transformer,

Tổng quan mô hình

2. EfficientNet-B0


Các mô hình mạng tích chập sử dụng chủ yếu ba cách để tăng kích thước: tăng độ rộng, độ sâu hoặc độ phân giải. Mặc dù ResNet đã đưa ra giải pháp để giải quyết vấn đề degradation, chi phí tính toán của các mô hình này vẫn tăng nhanh khi kích thước mô hình tăng.




Tổng quan mô hình

2. EfficientNet-B0

Nhóm tác giả của EfficientNet đã sử dụng phương pháp có tên là **compound scaling**. Thay vì mở rộng mô hình theo một tiêu chí riêng lẻ (độ sâu, độ rộng ,....) thì họ sẽ đồng thời mở rộng tất cả theo một tỷ lệ được tính toán trước



Kết quả thực nghiệm chứng minh rằng cân bằng các yếu tố cho kết quả tốt hơn trong khi chi phí tính toán thấp hơn đáng kể



Huấn luyện mô hình

1. Dự đoán ảnh

Với mô hình ResNet50 đã được tiền huấn luyện trên tập ImageNet1K, em đã thực hiện finetune trong 100 epochs, sử dụng hàm lỗi Cross Entropy, bộ tối ưu Adam và áp dụng phương pháp thay đổi learning rate khi mô hình có dấu hiệu chững lại.

	Mô hình	Precision	Recall	F1-Score	Accuracy	ROC-AUC
	ResNet-50	0.95	0.95	0.95	95.00	99
[4]	VGGNet	0.96	0.96	0.96	96.00	99
	DenseNet	0.98	0.98	0.98	98.00	99
[5]	Binary NeuralNet	N/A	N/A	N/A	97.35	99.62
Mine	ResNet-50	0.98	0.98	0.98	98.45	99.86


Kết quả thu được sau khi huấn luyện mô hình và so sánh với các mô hình mới nhất được huấn luyện trên cùng dữ liệu CIFAKE, tất cả đều được đo trên tập kiểm thử.

Huấn luyện mô hình

2. Dự đoán video

Do video là một dữ liệu đặc biệt, nên em sẽ áp dụng một vài phương pháp để huấn luyện mô hình EfficientNet-B0, vốn được tiền huấn luyện trên dự đoán ảnh.

- Xử lý dữ liệu: một video sẽ được tách ra thành các frames, và sẽ chỉ một vài frames được chọn để đại diện cho video đó, các biến đổi như chuẩn hóa, ... sẽ được thực hiện riêng lẻ trên từng ảnh.



Ưu điểm: video thường có kích thước rất lớn, nên việc chỉ lấy vài frames đại diện sẽ giảm rất nhiều chi phí tính toán, từ đó khiến cho quá trình huấn luyện nhanh hơn.

Nhược điểm: mô hình không thể học được quan hệ về mặt thời gian giữa các frames, thay vì đó nó chỉ dự đoán trên từng frames riêng lẻ rồi tổng hợp đưa ra kết quả cuối cùng

Huấn luyện mô hình

2. Dự đoán video

- Progressive finetuning: Do dữ liệu được tiền huấn luyện cho mô hình là các ảnh đơn lẻ, mà đầu vào của bài toán này lại là các chuỗi ảnh, nên em sẽ áp dụng phương pháp này để tối ưu quá trình huấn luyện của mô hình.

Quy trình của phương pháp này gồm hai bước:

1. Đóng băng toàn bộ tham số của mô hình, trừ lớp phân loại mới được thêm vào mô hình. Tập trung vào việc huấn luyện lớp phân loại để thích nghi với tác vụ mới.
2. Mở khóa toàn bộ tham số của mô hình cho việc huấn luyện, tuy nhiên learning rate sẽ đặt ở mức rất bé. Lý do là vì mô hình đã qua tiền huấn luyện đã có tri thức với các đặc trưng của ảnh, nên việc này sẽ giúp mô hình không bị thay đổi quá đột ngột, làm mất đi các tri thức này.

Phương pháp này được sử dụng rất phổ biến trong transfer learning, khi mà chúng ta muốn sử dụng mô hình tiền huấn luyện để phục vụ cho các tác vụ mới. Kết quả huấn luyện là **91.27% Accuracy** trên tập kiểm thử.

Tổng kết quá trình huấn luyện

- Qua quá trình huấn luyện, em đã đạt được **98.45% Accuracy** trên tập dữ liệu CIFAKE, cao hơn những model khác em có thể tìm thấy hiện tại được huấn luyện với cùng tác vụ trên cùng tập dữ liệu.
- Với huấn luyện video, em đã đạt được **91.27% Accuracy** trên một phần tập dữ liệu DFD, do tập dữ liệu được lấy ngẫu nhiên nên em chưa tìm được các mô hình tương tự khác được huấn luyện trên cùng tập dữ liệu.

A large, stylized graphic of the HUST logo, composed of many small red dots arranged in a circular pattern, filling the left half of the slide.

HUST

DEMO




HUST

**Ứng dụng mô
hình vào website**



Vấn đề thực tiễn

Với sự phát triển của công nghệ, phần lớn các nền tảng mạng xã hội (facebook, instagram, tiktok ,....) do người dùng tự đóng góp nội dung đã bắt đầu xuất hiện rất nhiều nội dung AI.




Tuy nhiên trong dự án này, em sẽ tập trung vào một case study thực tế mà Pinterest đang phải trải qua, đó là khi nền tảng của họ có quá nhiều ảnh do AI sinh ra.

Điều này khiến cho người dùng cảm thấy khó chịu khi một nền tảng để họ tìm kiếm các bức ảnh đẹp để lấy ý tưởng thì lại thấy phần lớn là các bức ảnh AI.

Trong dự án này, em sẽ xây dựng một website nơi mà người dùng có thể chia sẻ ảnh, và website sẽ cho người dùng biết rằng liệu nội dung họ xem có phải là nội dung AI hay không.

Em sẽ xây dựng website sử dụng techstack như hình dưới, với mongoDB sẽ là cơ sở dữ liệu online lưu trữ các thông tin như mật khẩu người dùng, ... còn Cloudinary sẽ sử dụng để lưu trữ các hình ảnh.



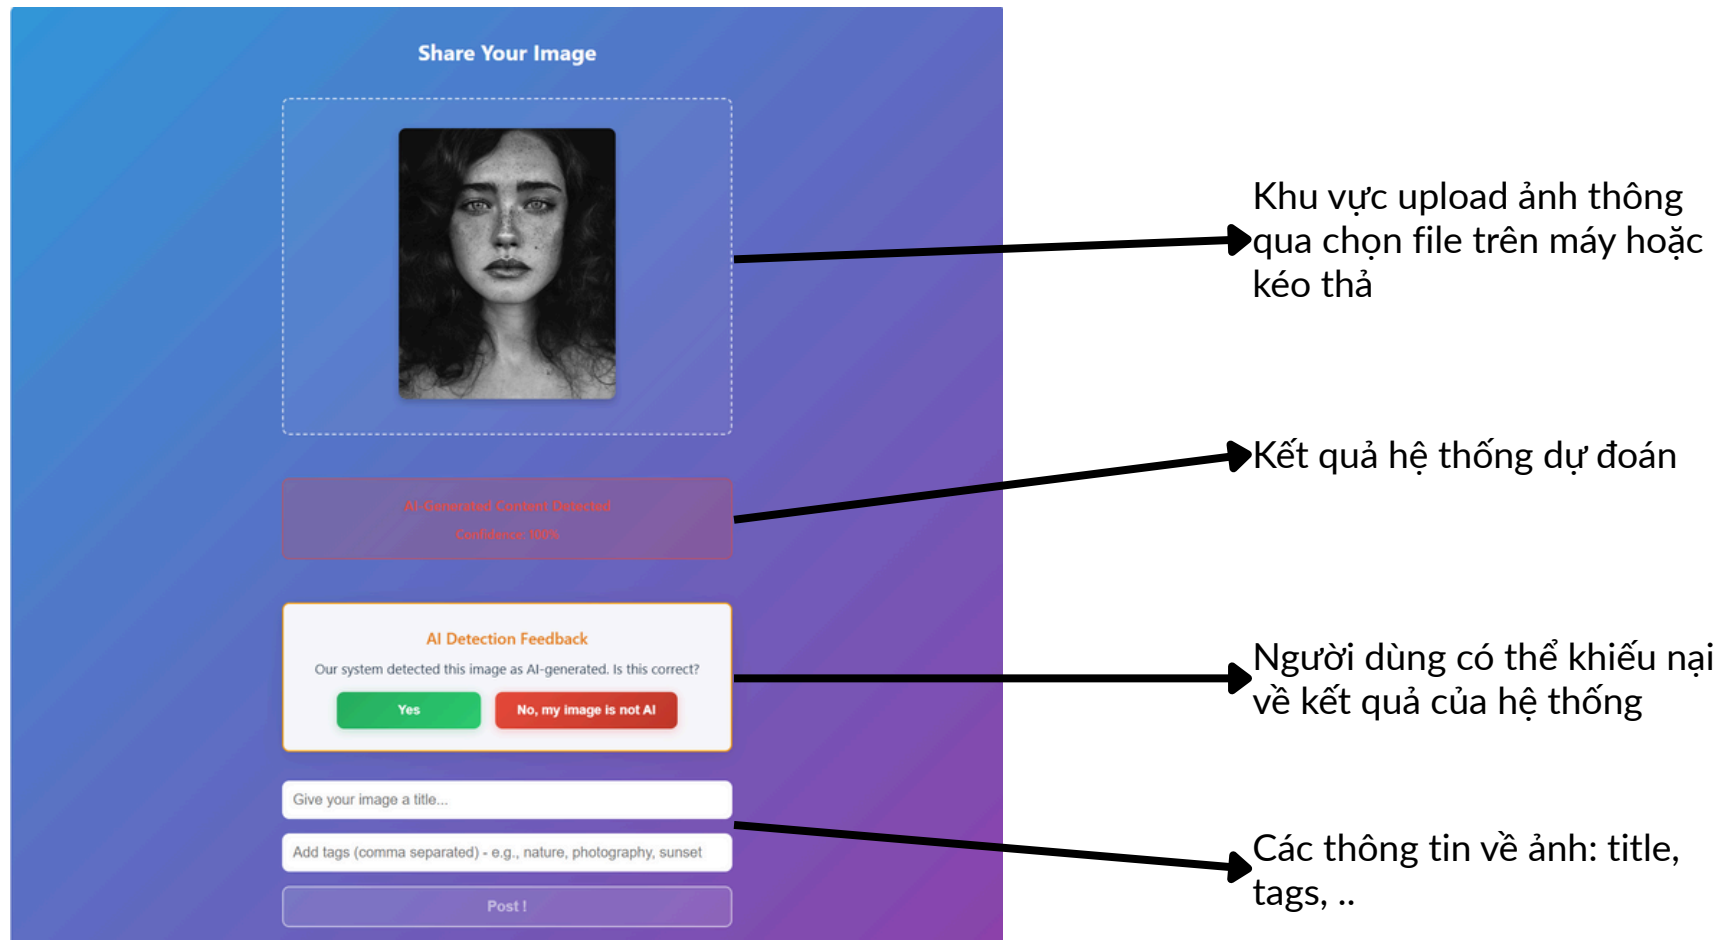
+



Các tính năng cơ bản

1.Upload ảnh

Người dùng có thể đăng ảnh họ chọn lên trang chủ thông qua giao diện sau:



The screenshot shows a web interface titled "Share Your Image" with a blue and purple gradient background. It features a dashed box for image upload, a red notification for AI-generated content detection, a feedback section with "Yes" and "No" buttons, and input fields for a title and tags, followed by a "Post !" button. Four arrows point from Vietnamese text labels to specific parts of the interface:

- An arrow points from the text "Khu vực upload ảnh thông qua chọn file trên máy hoặc kéo thả" to the dashed image upload box.
- An arrow points from the text "Kết quả hệ thống dự đoán" to the red "AI-Generated Content Detected" notification box.
- An arrow points from the text "Người dùng có thể khiếu nại về kết quả của hệ thống" to the "AI Detection Feedback" section, specifically the "No, my image is not AI" button.
- An arrow points from the text "Các thông tin về ảnh: title, tags, .." to the input fields for "Give your image a title..." and "Add tags (comma separated) - e.g., nature, photography, sunset".

Các tính năng cơ bản

2. Trang chủ xem ảnh

The screenshot shows a social media gallery interface with a 'Filter & Sort' section at the top. It includes a 'Content Type' filter with 'Hide AI Content' and 'AI Only' options, a 'Sort By' dropdown set to 'Newest First', and a 'Filter by Tag' input field. The main area displays a grid of image posts. Annotations with arrows point to specific features: one points to the 'Filter by Tag' input field, another points to a red 'AI' tag on a post, and a third points to the post's metadata (title, tags, user, date, views, likes, and date).

Filter & Sort

Content Type

Sort By

Filter by Tag

Hide AI Content

AI Only

Newest First

Enter tag...

feedback feature testing

#blackwhite

TienThanh

6/29/2025

1 0

image from cifake dataset

TienThanh

6/29/2025

1 0

this is suppose to be original content but the...

AI #face

tienthanh0805

6/1/2025

4 0 100%

picture from pinterest

AI #scenery

tienthanh0805

6/1/2025

6 1 100%

6/1

Tính năng lọc ảnh AI/Non AI và tìm kiếm theo tag


Tag AI nếu hệ thống cho rằng ảnh được đăng là AI

Thông tin về ảnh: title, tags, người đăng, số lượt views, likes, ngày đăng

Các tính năng cơ bản

3. Single file detection

Trong tính năng này người dùng có thể đăng ảnh hoặc video để hệ thống dự đoán, đồng thời có thể feedback để góp phần cải thiện hệ thống



Khu vực người dùng upload, chọn định dạng nội dung (image/video) và thực hiện dự đoán

Kết quả trả về cùng với nội dung người dùng đã chọn đăng tải


Tính năng feedback, khi thực hiện ở đây thì thông tin về feedback sẽ được lưu lại trên hệ thống như sau:

```
_id: ObjectId('68611beae340014147dff95e')
user_id: ObjectId('6829754b4e07895629e1cc57')
content_uploaded: "uploads\1751194598418-437240093.jpg"
detection_result: "deepfake"
user_feedback: "correct"
detection_time: 2025-06-29T10:56:42.824+00:00
__v: 0
```

Các tính năng cơ bản

4. Tương tác nội dung

Người dùng có thể tương tác với hình ảnh được đăng như thích và bookmark.




Ảnh được đăng

Các thông tin về ảnh như tag, người đăng, title, ngày đăng, lượt views cùng với tương tác như like hoặc bookmark

4. Tương tác nội dung

Người dùng có thể xem nội dung mình đã bookmark tại user's profile



Các tính năng cơ bản

5. User's profile

Người dùng có thể xem các thông tin cơ bản của bản thân cùng với các hình ảnh đã đăng trên nền tảng.

User Profile

The User Profile interface is divided into several sections:

- Account Information:** Username: TienThanh, Email: tien Thanh1805@gmail.com, Role: user.
- Detection Statistics:** Total detections: 12, Deepfakes detected: 9, Authentics detected: 3.
- My Posted Images (3):** Three image thumbnails are shown.
- My Bookmarks (1):** One image thumbnail is shown.
- Recent Detection History:** A table showing the results of recent detections.

Time	Result	Feedback
6/29/2025, 6:56:07 PM	DEEPPFAKE	Feedback: correct
6/29/2025, 6:33:04 PM	DEEPPFAKE	Feedback: correct
6/29/2025, 6:24:44 PM	DEEPPFAKE	Feedback: correct
6/29/2025, 6:00:16 PM	AUTHENTIC	Feedback: correct
6/29/2025, 5:59:42 PM	DEEPPFAKE	Feedback: correct

[View All History](#)

Thông tin cơ bản về người dùng, tương tác với hệ thống,


Các hình ảnh đã đăng, cùng với bookmark là các hình ảnh mà người dùng đã lưu

Lịch sử của tính năng single file detection


Các tính năng cơ bản

6. Đăng nhập/Đăng ký

Tính năng cơ bản nhất của web. Mật khẩu người dùng sẽ được lưu trữ dưới dạng mã hoá.




The screenshot shows the 'Login' page of the 'DeepFake Detector' application. The page has a dark blue header with the title 'DeepFake Detector' and a 'Login' link. The main content area is light blue and contains a white box with the 'Login' form. The form has two input fields: 'Username or Email' (containing 'admin') and 'Password' (containing six dots). Below the fields is a blue 'Login' button. At the bottom of the form, there is a link: 'Don't have an account? [Register](#)'. The footer of the page is dark blue and contains the text: 'Deepfake Detection Web - An application for HUST Project 2 course - By NTT | Contact: 0915160546'.



The screenshot shows the 'Register' page of the 'DeepFake Detector' application. The page has a dark blue header with the title 'DeepFake Detector' and a 'Login' link. The main content area is light blue and contains a white box with the 'Register' form. The form has four input fields: 'Username', 'Email', 'Password', and 'Confirm Password'. Below the fields is a blue 'Register' button. At the bottom of the form, there is a link: 'Already have an account? [Login](#)'. The footer of the page is dark blue and contains the text: 'Deepfake Detection Web - An application for HUST Project 2 course - By NTT | Contact: 0915160546'.

Demo bao gồm các chức năng cơ bản đã được đề cập trước đó



The screenshot displays a web browser window with the address bar showing 'localhost:3001/login'. The page title is 'Pinterest with AI DETECTION'. A 'Login' button is visible in the top right corner. The main content area features a central login form with the following elements:

- Login** (Section Header)
- Username or Email** (Label): Input field containing 'tienthanh1805@gmail.com'.
- Password** (Label): Input field with masked characters '•••'.
- Login** (Button): A blue button to submit the login credentials.
- Don't have an account? Register** (Text): A link to the registration page.

At the bottom of the page, there is a footer with the text: 'Deepfake Detection Web - An application for HUST Project 2 course - By NTT | Contact: 0915160546'.

A large, stylized graphic of the HUST logo, composed of a circular arrangement of small red dots on a dark red background.

HUST

THANK YOU !

